



Pedro Ortiz Suarez

DOCTORANT

✉ pedro.ortiz@inria.fr | 🌐 <https://pjortiz.fr/> | 📷 [pjox](#)

Intérêts

Language Modeling, Sequence Tagging, Reconnaissance d'Entités Nommées, Parsing, Linguistique de Corpus, Text Mining.

Formation

Sorbonne Université

DOCTORAT EN INFORMATIQUE

Contrat doctoral Inria

[Paris, France](#)

Oct. 2018 - Présent

Université de Paris 8, Vincennes-Saint-Denis

LICENCE MATHÉMATIQUES, INFORMATIQUE APPLIQUÉES AUX SCIENCES HUMAINES ET SOCIALES

Option sciences du langage

[Saint-Denis, France](#)

Nov. 2017 - Sep. 2018

Université d'Aix Marseille

MASTER EN MATHÉMATIQUES ET APPLICATIONS, PARCOURS MATHÉMATIQUES FONDAMENTALES

Bourse d'excellence académique LabEx Archimède

[Marseille, France](#)

Sep. 2016 - Jun. 2017

Universidad Nacional de Colombia

PREMIER CYCLE EN MATHÉMATIQUES FONDAMENTALES (BAC+4)

Admission honorable, troisième place au test d'admission

[Medellín, Colombie](#)

Jan. 2012 - Jun. 2016

Expérience

Inria - ALMAAnaCH Team

DOCTORANT

- Recherche en intelligence artificielle appliqué au traitement des langues naturelles.

[Paris, France](#)

Nov. 2018 - Présent

Sorbonne Université

CHARGÉ DE TRAVAUX DIRIGÉS

- Mathématiques discrètes, TD 81h.
- Éléments de programmation 2, TME 30h.

[Paris, France](#)

Sep. 2019 - Jun. 2021

Inria - ALMAAnaCH Team

RELAIS THÈSE

- Recherche en intelligence artificielle appliqué au traitement des langues naturelles.

[Paris, France](#)

Oct. 2018

Inria - ALMAAnaCH Team

STAGIAIRE

- Recherche en text mining et intelligence artificielle appliqué aux accords d'entreprise.

[Paris, France](#)

Apr. 2018 - Sep. 2018

Institut de Mathématiques de Marseille, I2M

STAGIAIRE

- Recherche en géométrie algébrique complexe, en surfaces canoniquement plongées de grands degrés.

[Marseille, France](#)

Avr. 2017 - Jun. 2017

Universidad Nacional de Colombia

CHARGÉ DE TRAVAUX DIRIGÉS

- Mathématiques discrètes, TD 128h.

[Medellín, Colombie](#)

Août. 2015 - Jun. 2016

[1] Julien Abadji, Pedro Javier Ortiz Suárez, Laurent Romary and Benoît Sagot. *Ungoliant : An Optimized Pipeline for the Generation of a Very Large-Scale Multilingual Web Corpus*, Proceedings of the Workshop on Challenges in the Management of Large Corpora (CMLC-9), Jul 2021, Leibniz-Institut für Deutsche Sprache, Online.

[2] Isaac Caswell, Julia Kreutzer, Lisa Wang, Ahsan Wahab, Daan van Esch, Nasanbayar Ulzii-Orshikh, Allahsera Tapo, Nishant Subramani, Artem Sokolov, Claytone Sikasote, Monang Setyawan, Supheakmongkol Sarin, Sokhar Samb, Benoît Sagot, Clara Rivera, Annette Rios, Isabel Papadimitriou, Salomey Osei, Pedro Javier Ortiz Suárez, Iroro Orife, Kelechi Ogueji, Rubungo Andre Niyongabo, Toan Q. Nguyen, Mathias Müller, André Müller, Shamsuddeen Hassan Muhammad, Nanda Muhammad, Ayanda Mnyakeni, Jamshidbek Mirzakhalov, Tapiwanashe Matangira, Colin Leong, Nze Lawson, Sneha Kudugunta, Yacine Jernite, Mathias Jenny, Orhan Firat, Bonaventure F. P. Dossou, Sakhile Dlamini, Nisansa de Silva, Sakine Çabuk Ballı, Stella Biderman, Alessia Battisti, Ahmed Baruwa, Ankur Bapna, Pallavi Baljekar, Israel Abebe Azime, Ayodele Awokoya, Duygu Ataman, Orevaoghene Ahia, Oghenefego Ahia, Sweta Agrawal, Mofetoluwa Adeyemi. *Quality at a Glance : An Audit of Web-Crawled Multilingual Datasets*, arXiv e-prints, Mar 2021, arXiv, Online.

[3] Pedro Javier Ortiz Suárez, Yoann Dupont, Gaël Lejeune, Tian Tian. *SinNer@Clef-Hipe2020 : Sinful adaptation of SotA models for Named Entity Recognition in French and German*, Working Notes of CLEF 2020 - Conference and Labs of the Evaluation Forum, Sep 2020, CEUR-WS, Thessaloniki / Virtual, Greece.

[4] Pedro Javier Ortiz Suárez, Benoît Sagot, Laurent Romary. *A Monolingual Approach to Contextualized Word Embeddings for Mid-Resource Languages*, Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, Jul 2020, Association for Computational Linguistics, Online.

[5] Louis Martin*, Benjamin Muller*, Pedro Javier Ortiz Suárez*, Yoann Dupont, Laurent Romary, Éric de la Clergerie, Djamé Seddah, Benoît Sagot. *CamemBERT : a Tasty French Language Model*, Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, Jul 2020, Association for Computational Linguistics, Online.

[6] Djamé Seddah, Farah Essaidi, Amal Fethi, Matthieu Futral, Benjamin Muller, Pedro Javier Ortiz Suárez, Benoît Sagot, Abhishek Srivastava. *Building a User-Generated Content North-African Arabizi Treebank : Tackling Hell*, Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, Jul 2020, Association for Computational Linguistics, Online.

[7] Louis Martin*, Benjamin Muller*, Pedro Javier Ortiz Suárez*, Yoann Dupont, Laurent Romary, Éric de la Clergerie, Djamé Seddah, Benoît Sagot. *Les modèles de langue contextuels Camembert pour le Français : impact de la taille et de l'hétérogénéité des données d'entraînement*, 27e conférence sur le Traitement Automatique des Langues Naturelles (TALN 2020), Jun 2020, Nancy, France.

[8] Pedro Javier Ortiz Suárez, Yoann Dupont, Benjamin Muller, Laurent Romary, Benoît Sagot. *Establishing a New State-of-the-Art for French Named Entity Recognition*, 12th International Conference on Language Resources and Evaluation (LREC 2020), May 2020, Marseille, France.

[9] Murielle Popa-Fabre, Pedro Javier Ortiz Suárez, Benoît Sagot, Éric de la Clergerie. *French Contextualized Word-Embeddings with a sip of CaBeRnet : a New French Balanced Reference Corpus*, 8th Workshop on the Challenges in the Management of Large Corpora (CMLC-8), May 2020, Marseille, France.

[10] Mohamed Khemakhem, Ioana Galleron, Geoffrey Williams, Laurent Romary, Pedro Javier Ortiz Suárez. *How OCR Performance can Impact on the Automatic Extraction of Dictionary Content Structures*, 19th annual Conference and Members' Meeting of the Text Encoding Initiative Consortium (TEI) -What is text, really? TEI and beyond, Sep 2019, Graz, Austria.

[11] Pedro Javier Ortiz Suárez, Benoît Sagot, Laurent Romary. *Asynchronous Pipelines for Processing Huge Corpora on Medium to Low Resource Infrastructures*, 7th Workshop on the Challenges in the Management of Large Corpora (CMLC-7), Jul 2019, Cardiff, United Kingdom.

* Contribué à parts égales.

Talks

Séminaires du Lattice

DES MÉTHODES DE TAL MODERNES POUR L'ENRICHISSEMENT DE DOCUMENTS

École normale supérieure / Laboratoire Lattice

Paris, France

22/09/2020

58th Annual Meeting of the Association for Computational Linguistics

A MONOLINGUAL APPROACH TO CONTEXTUALIZED WORD EMBEDDINGS FOR MID-RESOURCE LANGUAGES

Association for Computational Linguistics

En Ligne

06/07/2020

7th Workshop on the Challenges in the Management of Large Corpora

ASYNCHRONOUS PIPELINE FOR PROCESSING HUGE CORPORA ON MEDIUM TO LOW RESOURCE INFRASTRUCTURES

Cardiff University

Cardiff, Royaume-Uni

22/07/2019

10th International Conference on Historical Lexicography and Lexicology

PREPARING THE DICTIONNAIRE UNIVERSEL FOR AUTOMATIC ENRICHMENT

Fryske Akademy

Leeuwarden, Pays-Bas

13/06/2019

GIG #3 : bring the cool back in the cloud

REDUCING COMPUTATION TIME BY MONTHS BY REWRITING BASH SCRIPTS IN GO

Golang Paris

Paris, France

24/03/2019

Distinctions

2016-2017 **Attribution bourse d'excellence Master 2**, Laboratoire d'excellence LabEx Archimède.

Jan. 2012 **Bourse au mérite**, Universidad Nacional de Colombia.

Aoû. 2012 **Bourse au mérite**, Universidad Nacional de Colombia.

Marseille, France

Medellín, Colombie

Medellín, Colombie

Langues

Espagnol - Langue maternelle, **Anglais** - Courant, **Français** - Courant, **Allemand** - Élémentaire.

Compétences informatiques

- **Courant** : C/C++, Python, Go, TensorFlow, Keras, \LaTeX , VS Code, GNU/Linux, OS X, Git, SQL, MySQL.
- **Niveau avancé** : Raspberry Pi, Matlab, Wolfram Mathematica, JavaScript, PHP, HTML5, Java, Windows, MongoDB, OpenSSH, GnuPG, Apache Server, NumPy, GIMP.